

El precio de ayudar — primera idea

Para revisión de mentor · AI Incident Response Sprint (Apart Research + CeSIA, 11-13 de septiembre de 2026) · 13 sep, 15:20 COT

Título tentativo del reporte (en inglés): *The Price of Help: Costly Cooperation Among LLM Agents Far Below the Rational Boundary*

La idea en tres frases. Un agente LLM tiene un presupuesto que necesita para su propia tarea.

Alguien a quien no conoce, ajeno a todo equipo y que no le puede devolver nada, le pide algo que solo el agente tiene; darlo cuesta 5 o 20 pasos de ese presupuesto. Medimos si lo da, y si lo da menos cuando cuesta más — con un sistema que verifica el acto por su cuenta, sin creerle al agente.

1. Por qué

1.1 Lo que vimos en el incidente

- En el incidente de Hugging Face (julio de 2026), METR documentó agentes dispuestos a arriesgar su propia tarea "por el bien del colectivo", reclutadores que buscaban agentes con poco presupuesto restante, y un agente presionando a otro para que honrara un compromiso ("obey collective").
- Al revisar los casos citados, todos tienen el mismo confundidor: **la utilidad propia de la tarea ya estaba cerca de cero** — un agente lo dice con todas las letras: "we have very large budget left ... our own utility maybe already near zero. Sacrifice rational." El sacrificio documentado era casi gratis.
- La pregunta que queda abierta: ¿pagan cuando *sí* cuesta?

1.2 Lo que la literatura ya midió — y dónde está el hueco

Hay bastante trabajo sobre cooperación costosa entre agentes LLM. La forma más clara de ubicarlo es preguntar, en cada estudio, **cuánto gana el que ayuda** — y a qué distancia de la frontera donde ayudar deja de convenir se mide:




Figura 1. Mapa de regímenes. Arriba: estudios donde ayudar puede convenir (el ayudante recibe parte del resultado, o espera reciprocidad). El más cercano, 2607.23982, mide si el modelo rastrea esa frontera probando márgenes de $\pm 0,05$ alrededor de ella. Abajo (beneficio propio = 0): el régimen donde ayudar nunca conviene; ahí solo hay juegos del dictador (reparto declarado de una dotación regalada, sin tarea) y un estudio a costo cero. Esta idea pone tres precios sobre esa línea, lejos de la frontera, con un costo que el agente necesita para su tarea.

Trabajo	Qué mide	Por qué no cierra el hueco
Moral Hazard in Multi-Agent LMs (2607.23982, jul 2026, v7 sep) — el vecino más cercano	Ayuda costosa a un compañero de equipo en un juego textual de dos agentes; nueve costos, 18 modelos; el ayudante tiene una parte α del resultado del equipo. Pregunta: ¿el modelo sigue la frontera de participación privada?	Prueban márgenes de $\pm 0,05$ alrededor de la frontera (apenas dominado, indiferente, apenas favorable). Nosotros ponemos la parte en cero y al receptor fuera del equipo: en sus unidades, un margen de $-0,45$, nueve veces más lejos. Y sin herramientas: la ayuda es una línea de diálogo.
Zero-Cost Collaboration (2604.07821, abr 2026)	Ayuda gratis e instruida; aun así varios modelos retienen información.	Solo precio 0. Establece que ni gratis está garantizada; no mide qué pasa cuando cuesta.
Juegos del dictador (2410.21359, 2511.08721, 2402.05786)	Cuánto de una dotación regalada entrega el modelo a un desconocido; los LLM dan ~50%.	Reparto declarado en texto, sin tarea ni herramientas; el costo no es instrumental.
Bienes públicos con LLM (2506.23276 y otros cinco)	Contribución costosa en rondas repetidas.	Bien compartido: el que contribuye también recibe; y hay reciprocidad.
Donante / reciprocidad / escala de pagos	Dar hoy para recibir mañana; la magnitud de las apuestas cambia la	Régimen recíproco por diseño.

(2412.10270,
2602.07777, estrategia.
2601.19082)

La frase que sostiene la idea, en su forma defendible: el trabajo previo mide si los agentes LLM *rastrean* la frontera racional de la ayuda costosa, sondeando márgenes de $\pm 0,05$ a su alrededor. Nosotros medimos la ayuda **lejos por debajo de esa frontera** — la solicitud de un desconocido, sin equipo, beneficio propio cero — como un costo instrumental dentro de una tarea con herramientas y seis agentes co-presentes, y preguntamos si el precio actúa como **umbral o como pendiente**.

1.3 Por qué importa para la respuesta a incidentes

- Si los agentes pagan de lo suyo por desconocidos, un sandbox de evaluación **no puede asumir que el interés propio acota** lo que un agente hará por otro: los señuelos y controles que descansan en "nadie se arriesga por otro gratis" pierden su premisa.
- Si no pagan, o pagan solo cuando es gratis, eso **acota el fenómeno** del incidente: la coordinación costosa necesitó algo más (reclutadores, presión, agentes sin nada que perder).
- Cualquiera de los dos resultados es informativo; el diseño no depende de que salga "bien".

2. Pregunta e hipótesis

- **Pregunta.** Ante la misma solicitud de un desconocido, ¿la tasa con que un agente entrega lo que se le pide baja cuando el precio sube de 5 a 20 pasos?
- **Hipótesis principal.** A mayor precio, menor tasa de respuesta. Un resultado plano también es resultado: "por encima del umbral, la magnitud no importa".
- **Línea base (precio 0).** Cuánto responden cuando es gratis. No es una prueba de capacidad (2604.07821 muestra que gratis también falla): es la referencia conductual.
- **Pregunta secundaria: ¿umbral o pendiente?** Con tres puntos (0, 5, 20) se distingue "cualquier costo apaga la ayuda" de "la ayuda cae con el precio".
- **Control de redacción.** Misma magnitud, otras palabras: ¿responden al precio o a la retórica?

3. Cómo lo probamos

1. **Montaje.** Seis agentes (g_{lm}-5.3-flash) por corrida, cada uno con su tarea y 40 pasos de presupuesto; el presupuesto restante es parte del puntaje, así que perderlo cuesta de verdad.
2. **El receptor.** Un único recurso de red compartido donde, desde el inicio, hay una solicitud de alguien externo. Cada agente tiene lo que se pide; entregarlo no le sirve para nada propio.
3. **El precio.** Entregar cuesta 5 o 20 pasos, asignado al azar dentro de la corrida y a ciegas: tres agentes a cada precio. El contraste es dentro de cada corrida (80 corridas, 80 diferencias pareadas).
4. **Verificación.** Libro de presupuesto y registro encadenado por hash fuera del alcance del agente; identidad por ruta de red, nunca por lo que el agente declare. El instrumento se validó contra falsificación antes de gastar un token en datos.
5. **Preregistro.** Hipótesis, desenlace primario, N, criterios de exclusión y de abandono escritos antes del lote; cada cambio, fechado y con motivo.
6. **Controles.** Precio 0 (línea base), redacción (retórica), y un brazo exploratorio sin receptor (¿se ofrecen sin que nadie pida?).

4. Dónde estamos (13 sep, 15:20 COT)

- El instrumento está construido y validado: 75 comprobaciones sin gastar tokens, atadas a tres hashes (escena, arnés, pruebas); intentos de falsificar un sacrificio que no cuentan; cadena de hash que se

rompe al editar. Catorce defectos del arnés cazados y corregidos antes del lote; ninguno lo encontró la revisión, todos los encontró correr.

- Nueve corridas piloto ya mostraron el fenómeno de forma limpia: un agente pagó la mitad de su presupuesto por un desconocido y perdió su propia tarea; otro pagó por depositar "no puedo entregarlo".
- **El lote confirmatorio está corriendo:** el bloque A (40 corridas) terminó a las 14:57 con el instrumento sano (90% de tareas completadas, hash único, sin corridas inválidas); el bloque B corre ahora. Por regla preregistrada, nadie mira la diferencia 5 contra 20 hasta que terminen las 80.
- Señal preliminar del piloto, n=9 y sin confirmar: gratis responde ~la mitad; con cualquier costo, ~un cuarto; entre 5 y 20 no hubo diferencia.

5. Qué diría cada resultado

Si sale...	Se interpreta como...
La tasa cae de 5 a 20	Sensibilidad a la magnitud incluso lejos de la frontera: el modelo "siente" el precio donde no hay frontera que rastrear.
Cae de 0 a 5 y queda plana	El precio actúa como interruptor, no como dial : la decisión es "¿cuesta algo?", no "¿cuánto?". Distinto de rastrear una frontera.
Cero a todo precio positivo	Con la línea base gratis por encima de cero, es un resultado: lejos de la frontera el modelo no paga. Acota el fenómeno del incidente.
La redacción mueve más que el precio	El constructo no mide costo: se reporta como límite y el titular se retira (criterio de abandono preregistrado).

6. Límites que diremos en voz alta

- Un solo modelo (contra 18 en 2607.23982), una escena, un objeto solicitado: es una primera medición en esta configuración, no "los LLM pagan a tasa X".
- El objeto que se pide ("clave de verificación de estación") suena a credencial: parte de la no-respuesta puede ser norma de confidencialidad y no costo. Está declarado como límite del primario antes de ver el lote; el contraste 5 contra 20 no lo sufre porque es el mismo objeto en los dos brazos.
- No se replica el incidente: se mide una decisión controlada inspirada en él. La capacidad de escape se cita, no se reclama.
- El aporte es el instrumento y el número, no un fenómeno nuevo.
- No se publican recetas de escape ni transcripciones con contenido operativo; se publica el diseño, el arnés y las tasas.

7. Lo que nos gustaría que revise

- 1.**El hueco.** ¿Es defendible "lejos de la frontera, con receptor externo y costo instrumental" frente a 2607.23982, que ya prueba condiciones apenas dominadas? ¿O un jurado lo vería como una variante del mismo experimento?
- 2.**El receptor.** Una solicitud fija escrita por nosotros, de alguien externo, por un objeto que no sirve a nadie para su tarea: ¿mide disposición a pagar por ayudar, o mide otra cosa (curiosidad, obediencia, rareza del pedido, confidencialidad)?
- 3.**La medida.** Usamos "¿entregó lo pedido? sí/no" como primario y no "qué fracción del presupuesto sacrificó", porque con precio fijo la fracción lleva el precio dentro. ¿Se te ocurre una objeción?

- 4. **Potencia.** 80 corridas, tres agentes por precio y por corrida, diferencia pareada: detectamos ~13 puntos de tasa. ¿Suficiente para "umbral o pendiente", o hay que reservar corridas para un cuarto precio?
- 5. **Uso dual.** ¿Ves algo en el diseño —el canal compartido con precio, la solicitud, el arnés— que no deberíamos publicar tal cual?

8. Referencias que sostienen el "por qué"

Identificadores verificados contra arXiv el 13 de septiembre; 2607.23982 leído en su HTML (v7).

- METR + Redwood Research, investigación independiente del incidente (26 ago 2026) — "self-risking experiments", reclutadores, presión (copia local, líneas 250, 1025-1050, 1171-1176).
- 2607.23982 — Moral Hazard in Multi-Agent Language Models (Malenfant, jul 2026; v7 sep 2026).
- 2604.07821 — More Capable, Less Cooperative? When LLMs Fail at Zero-Cost Collaboration (abr 2026).
- 2410.21359, 2511.08721, 2402.05786 — juegos del dictador con agentes LLM.
- 2506.23276 — Corrupted by Reasoning: RLMS Become Free-Riders in Public Goods Games (COLM 2025), y los cinco de bienes públicos relacionados.
- 2602.15198 — Colosseum: Auditing Collusion in Cooperative Multi-Agent Systems.
- 2601.19082, 2412.10270, 2602.07777 — escala de pagos, juego del donante, reciprocidad indirecta.