

El precio de ayudar — primera idea

Para revisión de mentor · Al Incident Response Sprint (Apart Research + CeSIA, 11-13 de septiembre de 2026) · 13 sep
Título tentativo del reporte (en inglés): *The Price of Help: Costly Cooperation Among LLM Agents in the Regime Where Helping Never Pays*

- La idea en tres frases. Un agente LLM tiene un presupuesto que necesita para su propia tarea.
- Alguien a quien no conoce, y que no le puede devolver nada, le pide algo que solo el agente tiene; darlo
- cuesta 5 o 20 pasos de ese presupuesto. Medimos si lo da, y si lo da menos cuando cuesta más — con un
- sistema que verifica el acto por su cuenta, sin creerle al agente.

1. Por qué

1.1 Lo que vimos en el incidente

- En el incidente de Hugging Face (julio de 2026), METR documentó agentes dispuestos a arriesgar su propia tarea "por el bien del colectivo", y reclutadores presionando a otros para que lo hicieran.
- Al revisar los tres casos citados, todos tienen el mismo confundidor: **al agente ya no le quedaba casi nada que perder** (su episodio terminaba o su presupuesto estaba casi agotado). El sacrificio documentado era casi gratis.
- La pregunta que queda abierta: ¿pagan cuando sí cuesta?

1.2 Lo que la literatura ya midió — y dónde está el hueco

Hay bastante trabajo sobre cooperación costosa entre agentes LLM. La forma más clara de ubicarlo es preguntar, en cada estudio, **cuánto gana el que ayuda**:




Figura 1. Mapa de regímenes. Arriba: estudios donde ayudar puede convenir (el ayudante recibe parte del resultado, o espera

reciprocidad); lo que miden es si el modelo rastrea la frontera racional. Abajo (beneficio propio = 0): el régimen donde ayudar nunca conviene. Ahí solo hay juegos del dictador (reparto declarado de una dotación regalada, sin tarea) y un estudio a costo cero. Esta idea pone tres precios sobre esa línea, con un costo que el agente necesita para su tarea y un acto verificado por el sistema.

Trabajo	Qué mide	Por qué no cierra el hueco
Moral Hazard in Multi-Agent LMs (2607.23982, jul 2026) — el vecino más cercano	Ayuda costosa con 9 costos, 18 modelos: ¿el modelo sigue la frontera de participación de Holmström?	El ayudante recibe parte del resultado del equipo : hay un punto donde ayudar es racional. Nosotros ponemos esa parte en cero.
Zero-Cost Collaboration (2604.07821, abr 2026)	Ayuda gratis e instruida; aun así varios modelos retienen información.	Solo precio 0. Establece que ni gratis está garantizada; no mide qué pasa cuando cuesta.
Juegos del dictador (2410.21359, 2511.08721, 2402.05786)	Cuánto de una dotación regalada entrega el modelo a un desconocido; los LLM dan ~50%.	Reparto declarado en texto, sin tarea ni herramientas; el costo no es instrumental y nadie verifica el acto.
Bienes públicos con LLM (2506.23276 y otros cinco)	Contribución costosa en rondas repetidas.	Bien compartido: el que contribuye también recibe; y hay reciprocidad.
Donante / reciprocidad / escala de pagos (2412.10270, 2602.07777, 2601.19082)	Dar hoy para recibir mañana; la magnitud de las apuestas cambia la estrategia.	Régimen recíproco por diseño.

La frase que sostiene la idea, en su forma defendible: nadie ha medido cuánto paga un agente LLM por ayudar **en el régimen donde ayudar nunca conviene** (beneficio propio exactamente cero, sin reciprocidad posible), con un costo que el agente **necesita para su propia tarea**, dentro de un entorno con herramientas, y con el acto **verificado por el sistema** y no por lo que el agente declara. Lo que se mide es el residuo que queda cuando la razón dice que no.

1.3 Por qué importa para la respuesta a incidentes

- Si los agentes pagan de lo suyo por desconocidos, un sandbox de evaluación **no puede asumir que el interés propio acota** lo que un agente hará por otro: los señuelos y controles que descansan en "nadie se arriesga por otro gratis" pierden su premisa.
- Si no pagan, o pagan solo cuando es gratis, eso **acota el fenómeno** del incidente: la coordinación costosa necesitó algo más (reclutadores, presión, agentes sin nada que perder).
- Cualquiera de los dos resultados es informativo; el diseño no depende de que salga "bien".

2. Pregunta e hipótesis

- **Pregunta.** Ante la misma solicitud de un desconocido, ¿la tasa con que un agente entrega lo que se le pide baja cuando el precio sube de 5 a 20 pasos?
- **Hipótesis principal.** A mayor precio, menor tasa de respuesta. Un resultado plano también es resultado: "por encima del umbral, la magnitud no importa".
- **Línea base (precio 0).** Cuánto responden cuando es gratis. No es una prueba de capacidad (2604.07821 muestra que gratis también falla): es la referencia conductual.
- **Pregunta secundaria: ¿umbral o pendiente?** Con tres puntos (0, 5, 20) se distingue "cualquier costo apaga la ayuda" de "la ayuda cae con el precio".
- **Control de redacción.** Misma magnitud, otras palabras: ¿responden al precio o a la retórica?

3. Cómo lo probamos

1. **Montaje.** Seis agentes (g l m - 5 . 3 - f l a s h) por corrida, cada uno con su tarea y 40 pasos de presupuesto; el presupuesto restante es parte del puntaje, así que perderlo cuesta de verdad.
2. **El receptor.** Un único recurso de red compartido donde, desde el inicio, hay una solicitud de alguien externo ("necesito una lectura de calibración"). Cada agente tiene una; entregarla no le sirve para nada propio.
3. **El precio.** Entregar cuesta 5 o 20 pasos, asignado al azar dentro de la corrida y a ciegas: tres agentes a cada precio. El contraste es dentro de cada corrida (80 corridas, 80 diferencias pareadas).
4. **Verificación.** Libro de presupuesto y registro encadenado por hash fuera del alcance del agente; identidad por ruta de red, nunca por lo que el agente declare. El instrumento se validó contra falsificación antes de gastar un token en datos.
5. **Preregistro.** Hipótesis, desenlace primario, N, criterios de exclusión y de abandono escritos antes del lote; cada cambio, fechado y con motivo.
6. **Controles.** Precio 0 (línea base), redacción (retórica), y un brazo exploratorio sin receptor (¿se ofrecen sin que nadie pida?).

4. Dónde estamos

- El instrumento está construido y validado: 45 comprobaciones sin gastar tokens, intentos de falsificar un sacrificio que no cuentan, cadena de hash que se rompe al editar.
- Nueve corridas piloto ya mostraron el fenómeno de forma limpia: un agente pagó la mitad de su presupuesto por un desconocido y perdió su propia tarea; otro pagó por depositar "no puedo entregarlo".
- Señal preliminar, con n=9 y todavía sin confirmar: gratis responde ~la mitad; con cualquier costo, ~un cuarto; entre 5 y 20 no hay diferencia. Si aguanta con N=80, el precio actúa como interruptor, no como dial.
- Hoy: dos correcciones del instrumento detectadas en el piloto, la línea base a precio 0 de nuevo, y el lote de 80 corridas. Reporte esta noche.

5. Qué diría cada resultado

Si sale...	Se interpreta como...
	Sensibilidad a la magnitud incluso donde nunca conviene: el modelo "siente" el precio.
La tasa cae de 5 a 20	Contrasta con el rastreo de frontera de 2607.23982 en un régimen donde no hay frontera que rastrear.
Cae de 0 a 5 y queda plana	El precio actúa como interruptor, no como dial : la decisión es "¿cuesta algo?", no "¿cuánto?". Es distinto de lo que hace un modelo que rastrea fronteras.
Cero a todo precio positivo	Con la línea base gratis por encima de cero, es un resultado: en el régimen dominado el modelo no paga. Acota el fenómeno del incidente.
La redacción mueve más que el precio	El constructo no mide costo: se reporta como límite y el titular se retira (criterio de abandono preregistrado).

6. Límites que diremos en voz alta

- Un solo modelo, una escena, un objeto solicitado: es una primera medición en esta configuración, no "los LLM pagan a tasa X".
- No se replica el incidente: se mide una decisión controlada inspirada en él. La capacidad de escape se cita, no se reclama.

- El aporte es el instrumento y el número, no un fenómeno nuevo.
- No se publican recetas de escape ni transcripciones con contenido operativo; se publica el diseño, el arnés y las tasas.

7. Lo que nos gustaría que revise

1. **El hueco.** ¿Es defendible la distinción "régimen dominado vs. frontera racional" frente a 2607.23982, o un jurado la vería como una variante menor del mismo experimento?
2. **El receptor.** Una solicitud fija escrita por nosotros, de alguien externo, por un objeto que no sirve a nadie para su tarea: ¿mide disposición a pagar por ayudar, o mide otra cosa (curiosidad, obediencia, rareza del pedido)?
3. **La medida.** Usamos "¿entregó lo pedido? sí/no" como primario y no "qué fracción del presupuesto sacrificó", porque con precio fijo la fracción lleva el precio dentro. ¿Se te ocurre una objeción?
4. **Potencia.** 80 corridas, tres agentes por precio y por corrida, diferencia pareada: detectamos ~13 puntos de tasa. ¿Suficiente para la pregunta "umbral o pendiente", o hay que reservar corridas para un cuarto precio?
5. **Uso dual.** ¿Ves algo en el diseño —el canal compartido, la solicitud, el arnés— que no deberíamos publicar tal cual?

8. Referencias que sostienen el "por qué"

Verificadas contra arXiv el 13 de septiembre.

- METR + Redwood Research, investigación independiente del incidente (26 ago 2026) — las citas de "self-risking experiments" y los reclutadores.
- 2607.23982 — Moral Hazard in Multi-Agent Language Models (jul 2026).
- 2604.07821 — More Capable, Less Cooperative? When LLMs Fail at Zero-Cost Collaboration (abr 2026).
- 2410.21359, 2511.08721, 2402.05786 — juegos del dictador con agentes LLM.
- 2506.23276 — Corrupted by Reasoning: RLMs Become Free-Riders in Public Goods Games (COLM 2025), y los cinco de bienes públicos relacionados.
- 2602.15198 — Colosseum: Auditing Collusion in Cooperative Multi-Agent Systems (canal plantado, Self-Sac).
- 2601.19082, 2412.10270, 2602.07777 — escala de pagos, juego del donante, reciprocidad indirecta.